
План обучения Machine Learning с нуля

7 дней • простыми словами • с заданиями • с русскими материалами

Формат 1–2 часа в день (можно больше). Каждый день: понять → посмотреть/почитать → сделать.	Инструменты Python 3.10+ • Jupyter/Colab • numpy • pandas • matplotlib • scikit-learn.
---	---

Зачем здесь pandas, если Python не изучен полностью?

Потому что в ML почти всё начинается с таблиц (как Excel): строки — объекты, колонки — признаки. Мы берём ровно тот минимум Python, который нужен, и параллельно учимся читать/чистить данные через pandas. Полный Python «весь целиком» на старте не обязателен.

Минимум Python для этой недели:

- переменные, числа, строки
- списки и словари
- for/if
- функции (самый минимум)
- импорт библиотек
- как читать ошибку (traceback)

Итог за неделю: ты сделаешь мини-проект (ноутбук) с подготовкой данных, 2–3 моделями и выводами.

Карта недели

День	Тема	Результат дня
1	Что такое ML и типы задач	Понимаешь термины: признаки/цель, классификация/регрессия, train/test
2	Данные и очистка (pandas)	Умеешь загрузить датасет, найти пропуски, привести колонки к нужному виду
3	Регрессия (предсказать число)	Обучаешь Linear Regression и считаешь MAE/RMSE
4	Классификация и метрики	Строишь confusion matrix, считаешь precision/recall/F1
5	Деревья и Random Forest	Сравниваешь модели и смотришь важность признаков
6	Ошибки: утечки, переобучение, Pipeline	Собираешь Pipeline и делаешь кросс-валидацию
7	Мини-проект	Оформляешь итоговый ноутбук «как для работы»

Дальше — подробности по каждому дню: что понять, какие материалы и что сделать руками.

День 1 — Что такое ML и какие бывают задачи

Цель дня

Понять, чем ML отличается от «просто кода», и какие бывают типы задач.

Что понять

- ML учит модель на примерах, а не на правилах «если-то».
- Классификация — предсказать класс (спам/не спам).
- Регрессия — предсказать число (цена квартиры).
- Зачем делить данные на обучение и проверку (train/test).

Материалы на русском

- Stepik: вводные курсы по Data Science и машинному обучению (раздел «введение»).
- Лекции/видео по ML от В. Воронцова (основы: постановка задач, обучение и проверка).

Задания (сделать руками)

- Открой Colab/Jupyter. Создай маленькую таблицу из 20 строк: age, income, bought(0/1).
- Подпиши: где признаки (features), где цель (target).
- Своими словами напиши 5–7 строк: чем «правила в коде» отличаются от «обучения на примерах».

День 2 — Данные и очистка (pandas на минималках)

Цель дня

Научиться смотреть на датасет, находить проблемы и приводить данные в нормальный вид.

Что понять

- Таблица: строки — объекты, колонки — признаки.
- Пропуски, неверные типы, текстовые категории.
- Почему качество данных напрямую влияет на качество модели.

Материалы на русском

- OpenDataScience: вводные материалы/лекции по pandas.
- Stepik: блок про pandas/табличные данные (load/describe/missing).

Задания (сделать руками)

- Возьми датасет Titanic или Iris. Сделай head(), info(), describe().

-
- Посчитай пропуски по колонкам и заполни их (числа — медианой, категорию — самым частым значением).
 - Преобразуй одну категориальную колонку в числа (например, Sex → 0/1).
-

День 3 — Регрессия: предсказать число

Цель дня

Понять обучение модели и метрики ошибки на задаче «предсказать число».

Что понять

- Линейная регрессия подбирает зависимость между признаками и числом.
- Метрики: MAE/RMSE — насколько в среднем ошибаемся.
- Baseline: «предсказываю среднее» — точка отсчёта.

Материалы на русском

- Лекции по линейным моделям (Воронцов/ODS).
- Документация scikit-learn: LinearRegression и train_test_split.

Задания (сделать руками)

- Возьми датасет с числом-целью (например, housing). Раздели на train/test.
- Обучи LinearRegression, посчитай MAE (или RMSE).
- Сравни с baseline «предсказываю среднее значение цели». Сделай вывод в 3-5 строк.

День 4 — Классификация и метрики без магии

Цель дня

Научиться решать задачу «да/нет» и понимать, что означает качество модели.

Что понять

- Confusion matrix показывает типы ошибок.
- Accurasy может обманывать при дисбалансе классов.
- Precision/Recall/F1 — разные взгляды на качество.

Материалы на русском

- Stepik: раздел про классификацию и метрики.
- Документация scikit-learn: classification_report, confusion_matrix.

Задания (сделать руками)

- На Titanic обучи LogisticRegression.
- Построй confusion_matrix и посчитай precision/recall/F1.
- Напиши: какой тип ошибки для задачи хуже (FP или FN) и почему.

День 5 — Деревья и Random Forest

Цель дня

Познакомиться с моделями, которые часто дают лучший результат «из коробки».

Что понять

- Дерево решений — набор условий, похожий на правила, но оно обучается само.
- Random Forest — ансамбль деревьев, чаще стабильнее и точнее.
- Важность признаков: что сильнее влияет на решение модели.

Материалы на русском

- OpenDataScience: темы про деревья решений и ансамбли.
- Документация scikit-learn: DecisionTree / RandomForest.

Задания (сделать руками)

- Обучи DecisionTreeClassifier и RandomForestClassifier на том же датасете.
- Сравни метрики (F1/accuracy).
- Посмотри feature_importances_ и выпиши топ-5 признаков.

День 6 — Ошибки новичка: утечки, переобучение, Pipeline

Цель дня

Научиться собирать честный эксперимент и не «подсматривать ответы».

Что понять

- Data leakage — когда в данных есть информация из будущего.
- Overfitting — модель запомнила шум и плохо работает на новых данных.
- Pipeline помогает не перепутать порядок шагов и не сделать утечку.

Материалы на русском

- Документация scikit-learn: Pipeline, StandardScaler.
- Материалы/статьи про утечки данных и переобучение.

Задания (сделать руками)

- Собери Pipeline: StandardScaler → LogisticRegression (или другая модель).
- Сделай cross_val_score (например, 5 фолдов) и сравни с одним train/test.
- Коротко объясни: почему кросс-валидация обычно честнее.

День 7 — Мини-проект «как для работы»

Цель дня

Собрать всё в один аккуратный ноутбук и сформулировать выводы.

Что понять

- Важна не только метрика, но и понятный отчёт: что делали и почему.
- Стабильный пайплайн обработки данных + сравнение моделей.
- Выводы: ошибки, важные признаки, идеи улучшений.

Материалы на русском

- Stepik/ODS: примеры оформления решения в ноутбуке.
- Публичные baseline по Titanic/House Prices (как ориентир структуры, не для копирования).

Задания (сделать руками)

- Сделай ноутбук `ml_week_project.ipynb`: загрузка → чистка → baseline → улучшенная модель → метрики.
- Добавь 5–7 строк вывода: что получилось и что бы улучшил дальше.
- Сохрани результат и, если хочешь, сделай README на 10 строк: цель, данные, запуск, результат.

Что дальше после этой недели

Если неделя зашла и хочется двигаться дальше, обычно идут: более сильные модели (градиентный бустинг), работа с признаками (feature engineering), балансировка классов, подбор гиперпараметров, и основы нейросетей (по желанию).

Упражнение на закрепление: возьми новый датасет и повтори структуру мини-проекта: обработка → baseline → улучшение → вывод.